Kelompok 6

- Fawwas Aliy 235150300111009
- Briliiant Akhmad Assiddiqqy 235150301111045
- Andan Riski Mustari 235150301111002

Sumber/Repo: github.com/FechL/pid-uts-praktik-etl

Soal 1: Batch Processing

Membuat batch pipeline menggunakan Python dan Pandas untuk memproses data sensor_data_raw.csv. Tugasnya meliputi pembersihan data (mengisi suhu kosong dengan median), menghitung rata-rata suhu serta kelembapan maksimum per truk, dan menyimpan hasil ke file CSV. Soal ini menilai kemampuan dasar pemrosesan data terprogram.

Preparation

Impor library pandas untuk menampung dataset.

```
import pandas as pd
```

Function

Terdapat 2 function untuk cleaning data (missing values) dan menghitung agregasi.

```
def clean_sensor_data(df):
    df.fillna(df.median(numeric_only=True), inplace=True)
    return df

def calculate_aggregates(df):
    agregasi_df = df.groupby('truck_id').agg(
        avg_temp=('temperature_kelvin', 'mean'),
        max_humidity=('humidity_percent', 'max'),
    ).round(2).reset_index()
    return agregasi_df
```

Main

Load dataset dari datasets/sensor_data_raw.csv dan menamiplkan informasi dari data tersebut.

```
df = pd.read_csv('datasets/sensor_data_raw.csv')
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45 entries, 0 to 44
Data columns (total 8 columns):
    Column
                     Non-Null Count Dtype
    _ _ _ _ _
                                    ----
                     45 non-null
  truck_id
                                     object
0
                     45 non-null
    sensor_id
1
                                     object
2 timestamp
                     45 non-null
                                     object
3 temperature_kelvin 44 non-null
                                     float64
4 humidity_percent 44 non-null
                                     float64
5 gps_lat
                     45 non-null
                                    float64
                     45 non-null
6
    gps_lng
                                    float64
7
    engine_status 45 non-null
                                     object
dtypes: float64(4), object(4)
memory usage: 2.9+ KB
```

Terlihat bahwa pada kolom temperature_kelvin dan humidity_percent terdapat data yang tidak komplit atau missing. Data missing tersebut diimputasi menggunakan median.

```
cleaned_df = clean_sensor_data(df)
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45 entries, 0 to 44
Data columns (total 8 columns):
    Column
                      Non-Null Count Dtype
--- -----
                      -----
                                      ----
                      45 non-null
0
    truck id
                                      object
1 sensor_id
                                      object
                     45 non-null
    timestamp
                      45 non-null
2
                                      object
3 temperature_kelvin 45 non-null
                                     float64
4 humidity_percent 45 non-null
5 gps_lat 45 non-null
                                     float64
5 gps_lat
                                     float64
6
  gps_lng
                     45 non-null
                                     float64
7
    engine_status
                     45 non-null
                                     object
dtypes: float64(4), object(4)
memory usage: 2.9+ KB
```

Setelah cleaning data, dataset sudah tidak ada missing value. Kemudian kita mengagregasi dataset tersebut per truck_id dan menghitung average temp dan max kelembapan setiap truck_id.

```
result_df = calculate_aggregates(cleaned_df)
print(result_df)
```

```
truck_id avg_temp max_humidity
0
  TRK001
          301.57
                         69.8
   TRK002
                          70.2
1
            298.52
2
  TRK003
                          77.8
          304.65
         298.93
3
   TRK004
                          67.5
4
  TRK005
          301.42
                          73.1
   TRK006
           298.12
                          64.9
  TRK007 300.52
                          68.5
         297.02
7
   TRK008
                          63.4
  TRK009
           301.72
                         71.8
   TRK010
            299.22
                          66.9
```

Simpan hasil agregasi tersebut ke datasets/aggregated_results.csv

```
result_df.to_csv('datasets/aggregated_results.csv', index=False)
```

Soal 2: Database Implementation

Menguji implementasi database di MySQL dan MongoDB. Mahasiswa harus membuat tabel trucks dan sensors di MySQL dengan query JOIN, lalu mendesain koleksi sensor_readings di MongoDB serta menulis query pencarian dan agregasi. Fokus utamanya adalah penerapan konsep relasional dan non-relasional.

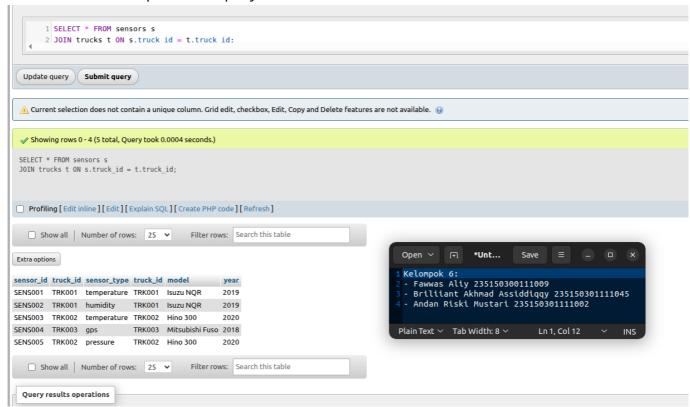
Bagian A: MySQL Implementation

```
-- 1. Membuat tabel trucks
CREATE TABLE IF NOT EXISTS trucks (
    truck_id VARCHAR(10) PRIMARY KEY,
   model VARCHAR(50),
   year INT
);
-- 2. Membuat tabel sensors dengan relasi ke trucks
CREATE TABLE IF NOT EXISTS sensors (
    sensor_id VARCHAR(10) PRIMARY KEY,
   truck_id VARCHAR(10),
   sensor_type VARCHAR(20),
    FOREIGN KEY (truck_id) REFERENCES trucks(truck_id)
);
-- 3. Insert sample data (3 trucks, 5 sensors)
INSERT INTO trucks (truck_id, model, year) VALUES
('TRK001', 'Isuzu NQR', 2019),
('TRK002', 'Hino 300', 2020),
('TRK003', 'Mitsubishi Fuso', 2018);
INSERT INTO sensors (sensor_id, truck_id, sensor_type) VALUES
```

```
('SENS001', 'TRK001', 'temperature'),
('SENS002', 'TRK001', 'humidity'),
('SENS003', 'TRK002', 'temperature'),
('SENS004', 'TRK003', 'gps'),
('SENS005', 'TRK002', 'pressure');

-- 4. Query untuk menampilkan semua sensors dengan informasi truck
SELECT
    s.sensor_id,
    s.sensor_type,
    t.truck_id,
    t.model,
    t.year
FROM sensors s
JOIN trucks t ON s.truck_id = t.truck_id
ORDER BY t.truck_id, s.sensor_id;
```

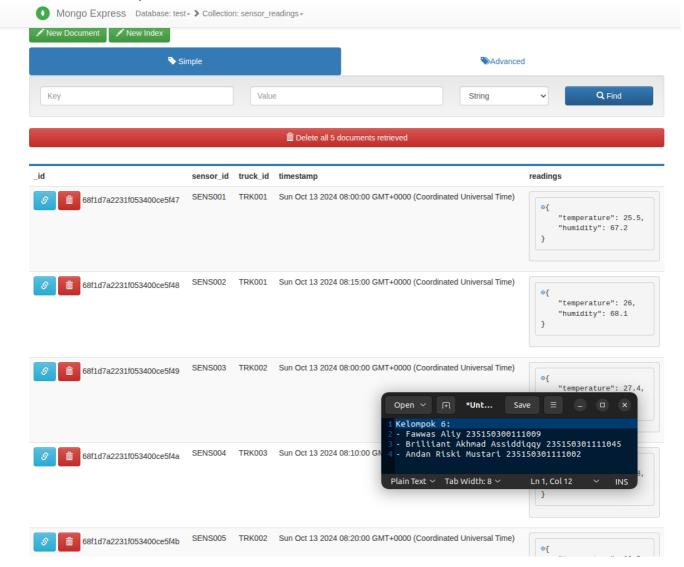
Berikut screenshot implementasi query:



Bagian B: MongoDB Document Design

```
},
    {
        "sensor_id": "SENS002",
        "truck_id": "TRK001",
        "timestamp": ISODate("2024-10-13T08:15:00Z"),
        "readings": {
            "temperature": 26.0,
            "humidity": 68.1
        }
    },
        "sensor_id": "SENS003",
        "truck_id": "TRK002",
        "timestamp": ISODate("2024-10-13T08:00:00Z"),
        "readings": {
            "temperature": 27.4,
            "humidity": 64.5
        }
    },
    {
        "sensor_id": "SENS004",
        "truck_id": "TRK003",
        "timestamp": ISODate("2024-10-13T08:10:00Z"),
        "readings": {
            "temperature": 23.8,
            "humidity": 70.2
        }
    },
    {
        "sensor_id": "SENS005",
        "truck_id": "TRK002",
        "timestamp": ISODate("2024-10-13T08:20:00Z"),
        "readings": {
            "temperature": 28.5,
            "humidity": 62.0
        }
    }
]);
// 2. Query untuk menampilkan semua readings dari truck tertentu (misal
TRK001)
db.sensor_readings.find({ truck_id: "TRK001" });
// 3. (Opsional) Query untuk menampilkan sensor dengan suhu di atas 26°C
db.sensor_readings.find({ "readings.temperature": { $gt: 26 } });
```

Berikut screenshot implementasi:



Soal 3: Advanced SQL dengan Window Functions

mMnggunakan fungsi window SQL seperti ROW_NUMBER(), AVG() OVER, LAG(), dan RANK() untuk menganalisis data sensor. Hasilnya menampilkan urutan pembacaan, rata-rata suhu per truk, selisih suhu antarwaktu, dan peringkat suhu tertinggi. Soal ini menilai kemampuan analisis data SQL tingkat lanjut.

```
WITH temperature_analysis AS (
    SELECT
    sensor_id,
    temperature,
    recorded_at,
    LAG(temperature) OVER (
        PARTITION BY sensor_id
        ORDER BY recorded_at
    ) AS prev_temp
    FROM sensor_readings_hist
),
anomalies AS (
    SELECT
```

```
sensor_id,
temperature AS current_temp,
prev_temp,
ABS(temperature - prev_temp) AS temp_diff,
CASE
    WHEN ABS(temperature - prev_temp) > 15 THEN 'HIGH'
    WHEN ABS(temperature - prev_temp) > 10 THEN 'MEDIUM'
    ELSE 'LOW'
    END AS anomaly_level
    FROM temperature_analysis
    WHERE prev_temp IS NOT NULL
)
SELECT *
FROM anomalies
WHERE temp_diff > 10
ORDER BY temp_diff DESC;
```

Berikut screenshot implementasi query:



Soal 4: Simple ETL Pipeline

Membangun pipeline ETL sederhana dari JSON ke CSV. Prosesnya mencakup extract dan flatten data JSON, transform dengan konversi suhu ke Fahrenheit serta perhitungan comfort index, lalu load hasil ke file CSV. Soal ini menilai pemahaman alur pemrosesan data mentah.

Preparation

Impor library yang dibutuhkan yaitu pandas untuk mengelola data dan json untuk membaca data json.

```
import pandas as pd
import json
```

Function

Fungsi berupa Extract, Transform, dan Load.

```
def extract_json_data(file_path):
    # baca file sensor
    with open(file_path, "r") as f:
        data = json.load(f)
    # baca nested array
    rows = []
    for sensor in data:
        sensor_id = sensor["sensor_id"]
        truck_id = sensor["truck_id"]
        for reading in sensor["readings"]:
            rows.append({
                "sensor_id": sensor_id,
                "truck_id": truck_id,
                "timestamp": reading["timestamp"],
                "temp": reading["temp"],
                "humidity": reading["humidity"]
            })
    df = pd.DataFrame(rows)
    return df
def transform_data(df):
    # ubah celsius ke fahrenheit
    df["temp"] = df["temp"] * 9/5 + 32
    # kalkulasi comfort index
    df["comfort_index"] = (df["temp"] / df["humidity"]) * 100
    df = df.round({"temp": 2, "comfort_index": 2})
    return df
def load_to_csv(df, output_path):
    # simpan ke path output
    df.to_csv(output_path, index=False)
    print(f"Data berhasil disimpan ke {output_path}")
```

Main

Ambil raw data pada datasets/sensors_2024-10-13.json dan extract data tersebut.

```
raw_data = extract_json_data('datasets/sensors_2024-10-13.json')
print(raw_data.head())
```

```
sensor_id truck_id timestamp temp humidity
0 SENS001 TRK001 2024-10-13T08:00:00Z 25.0 65.0
```

```
1 SENS001 TRK001 2024-10-13T08:15:00Z 28.1 67.0
2 SENS001 TRK001 2024-10-13T08:30:00Z 26.7 66.0
3 SENS002 TRK002 2024-10-13T08:00:00Z NaN 70.0
4 SENS002 TRK002 2024-10-13T08:15:00Z 22.3 NaN
```

Setelah di extract, beberapa parameter di transform terlebih dahulu.

```
transformed_data = transform_data(raw_data)
print(transformed_data.head())
```

```
sensor_id truck_id
                               timestamp
                                        temp
                                               humidity comfort_index
   SENS001 TRK001 2024-10-13T08:00:00Z 77.00
                                                   65.0
0
                                                               118.46
   SENS001 TRK001 2024-10-13T08:15:00Z 82.58
                                                   67.0
1
                                                               123.25
2
   SENS001 TRK001 2024-10-13T08:30:00Z 80.06
                                                   66.0
                                                               121.30
3
   SENS002 TRK002 2024-10-13T08:00:00Z
                                           NaN
                                                   70.0
                                                                  NaN
   SENS002 TRK002 2024-10-13T08:15:00Z 72.14
4
                                                    NaN
                                                                  NaN
```

Setelah itu output disimpan ke csv.

```
load_to_csv(transformed_data, 'etl_oupt.csv')
```

Data berhasil disimpan ke etl_oupt.csv

Soal 5: Data Quality Validation

Mengembangkan class DataQualityChecker untuk mendeteksi missing values, nilai di luar rentang wajar, dan data duplikat pada dataset sensor. Hasil pemeriksaan ditampilkan dalam laporan ringkas. Soal ini menguji kemampuan validasi dan penjaminan kualitas data sebelum analisis.

Preparation

Impor library pandas untuk pengeloalaan data.

```
import pandas as pd
```

Sampel data dengan beberapa maasalah kualitas dan data yang bersih.

```
None},  # Missing values
    {"sensor_id": "SENS001", "truck_id": "TRK001", "temp": 25.5,
"humidity": 65}, # Duplicate
    {"sensor_id": "SENS001", "truck_id": "TRK001", "temp": 25.5,
"humidity": 65} # Duplicate
])
test_data_bersih = pd.DataFrame([
    {"sensor_id": "SENS001", "truck_id": "TRK001", "temp": 25.5,
"humidity": 65},
    {"sensor_id": "SENS002", "truck_id": "TRK002", "temp": 27.0,
"humidity": 60},
    {"sensor_id": "SENS003", "truck_id": "TRK003", "temp": 22.3,
"humidity": 70},
    {"sensor_id": "SENS004", "truck_id": "TRK004", "temp": 30.1,
"humidity": 55}
])
```

Class Function

Berisikan beberapa function atau method untuk mengecek kualitas data.

```
class DataQualityChecker:
   def __init__(self):
       self.violations = []
   def check_missing_values(self, df, required_columns):
        # Mengecek nilai yang hilang di kolom yang diperlukan
        for col in required_columns:
            missing = df[col].isnull().sum() + (df[col] == "").sum()
                self.violations.append(f"Data hilang ditemukan di kolom
'{col}': {missing} baris")
   def check_value_ranges(self, df):
       # Mengecek nilai yang tidak valid di kolom temp dan humidity
        invalid\_temp = df[(df["temp"] < -40) | (df["temp"] > 80)]
        if not invalid_temp.empty:
            self.violations.append(f"Nilai temperature tidak valid:
{len(invalid_temp)} baris")
        invalid_hum = df[(df["humidity"] < 0) | (df["humidity"] > 100) |
(df["humidity"].isnull())]
        if not invalid_hum.empty:
            self.violations.append(f"Nilai humidity tidak valid:
{len(invalid_hum)} baris")
   def check_duplicates(self, df, key_columns):
       # Mengecek duplikat berdasarkan argumen kolom
        duplicates = df[df.duplicated(subset=key_columns, keep=False)]
        if not duplicates.empty:
```

```
self.violations.append(f"Duplikasi data ditemukan:
{len(duplicates)} baris")

def generate_report(self):
    # Menghasilkan laporan kualitas data
    if not self.violations:
        return "Tidak ada kesalahan kualitas data ditemukan. Data sudah
bersih."

report = "Terdapat kesalah data.\nData kualitas report:\n"
for v in self.violations:
    report += f"- {v}\n"
return report
```

Main

Testing data kotor.

```
checker1 = DataQualityChecker()
checker1.check_missing_values(test_data_kotor, ['sensor_id', 'truck_id'])
checker1.check_value_ranges(test_data_kotor)
checker1.check_duplicates(test_data_kotor, ['sensor_id', 'truck_id'])
report = checker1.generate_report()
print(report)
```

```
Terdapat kesalah data.
Data kualitas report:
- Data hilang ditemukan di kolom 'truck_id': 1 baris
- Nilai temperature tidak valid: 1 baris
- Nilai humidity tidak valid: 2 baris
- Duplikasi data ditemukan: 3 baris
```

Testing data bersih.

```
checker2 = DataQualityChecker()
checker2.check_missing_values(test_data_bersih, ['sensor_id', 'truck_id'])
checker2.check_value_ranges(test_data_bersih)
checker2.check_duplicates(test_data_bersih, ['sensor_id', 'truck_id'])
report = checker2.generate_report()
print(report)
```

Tidak ada kesalahan kualitas data ditemukan. Data sudah bersih.

Kesimpulan

Kelima soal UTS Arsitektur Sistem Data membentuk pemahaman utuh tentang pengelolaan data dari akuisisi hingga validasi. Soal pertama melatih pembersihan dan agregasi data dengan Python, soal kedua mengenalkan implementasi MySQL dan MongoDB, soal ketiga menerapkan analisis anomali dengan SQL Window Functions, soal keempat membangun pipeline ETL sederhana, dan soal kelima menekankan pentingnya validasi kualitas data. Secara keseluruhan, rangkaian soal ini menggambarkan alur kerja arsitektur data modern secara terintegrasi dan praktis.